



CURSO DE INTELIGENCIA ARTIFICIAL DESDE CERO

MÓDULO 0

¿Qué es realmente la IA?

Bases conceptuales: de los mitos comerciales a la disciplina matemática y de ingeniería



Edición ilustrada 2026 · Guía paso a paso · Nivel: cero absoluto

No necesitas saber programar ni matemáticas avanzadas para leer este módulo.



ANTES DE EMPEZAR

Cómo usar esta guía

Este libro está diseñado como una **revista educativa a color**: cada tipo de contenido tiene su propia caja con un ícono y un color, para que tu cerebro identifique de un vistazo qué está leyendo. Esta es la leyenda que verás en todo el módulo:

Caja	Color	¿Para qué sirve?
 Concepto clave	Azul	Definiciones que debes dominar. Son los ladrillos del curso.
 Ejemplo	Morado	Casos reales o analogías que aterrizan la teoría.
 Tip práctico	Amarillo	Consejos, atajos y recomendaciones de la vida real.
 Mito / Cuidado	Rojo	Ideas falsas muy comunes que hay que desmontar.
 Mini-actividad	Verde azulado	Pausas activas de 2 a 5 minutos para practicar.
 Reto	Verde	Tareas evaluables al final del módulo.

Recomendación de estudio

Lee el módulo en **dos pasadas**: la primera de corrido, sin detenerte, para tener el mapa general; la segunda con lápiz y papel, haciendo las mini-actividades. La neurociencia del aprendizaje llama a esto *codificación en dos fases*: primero panorama, luego detalle.

Objetivo del módulo

Romper los mitos de la IA comercial y entenderla como lo que realmente es: una **disciplina matemática y de ingeniería**. Al terminar, cuando alguien diga “la IA piensa” o “la IA lo sabe todo”, tú podrás explicar con precisión qué ocurre de verdad dentro de la máquina.

Al finalizar este módulo podrás...

- ▶ Distinguir con exactitud entre **IA, Machine Learning, Deep Learning y GenAI** (y corregir a quien las confunda).
- ▶ Explicar la diferencia entre **entrenamiento e inferencia**, y cómo “aprende” una máquina a partir de datos.
- ▶ Entender qué son los **pesos y parámetros**, y calcular cuánta memoria necesita un modelo.

- Decidir cuándo conviene un **modelo gigante en la nube** y cuándo un **modelo pequeño local (SLM)**.

Requisitos previos

Ninguno. Cero programación, cero matemáticas universitarias. Solo curiosidad. Los fragmentos de código que aparecen son *ilustrativos*: se explican línea por línea y no necesitas ejecutarlos para entender el módulo.

Mapa del módulo

Sección	Tema	Pregunta que responde
0.1	Taxonomía de la IA	¿Qué es cada cosa y cómo se relacionan entre sí?
0.2	Ciclo de vida de un modelo	¿Cómo “aprende” una máquina y qué pasa cuando la usas?
0.3	Anatomía física de la IA	¿De qué está hecho un modelo y qué hardware necesita?
0.4	Fundacionales vs. SLMs	¿Gigante en la nube o pequeño en tu computador?
	Tres retos prácticos	¿Cómo compruebo que de verdad lo entendí?

SECCIÓN 0.1

Taxonomía de la IA: IA, ML, DL y GenAI

Cuando el marketing dice “nuestro producto tiene IA”, casi nunca aclara **qué tipo** de IA. Y no es un detalle menor: un termostato con reglas, un filtro de spam y un chatbot que escribe poemas son tecnologías radicalmente distintas, con costos, límites y riesgos diferentes. Esta sección te da el mapa para no volver a perderte.

 La idea central: muñecas rusas

Los cuatro términos **no son sinónimos ni rivales**: son **capas anidadas**, como muñecas rusas (matrioskas). Cada capa interior es un subconjunto más especializado de la anterior:

IA $\supset$ Machine Learning $\supset$ Deep Learning $\supset$ IA Generativa

Léelo así: *toda* GenAI es Deep Learning, todo Deep Learning es Machine Learning y todo Machine Learning es IA... pero **no al revés**.

El diagrama de capas

 INTELIGENCIA ARTIFICIAL (IA) — desde 1956

El campo completo: lograr que las máquinas realicen tareas que asociamos con inteligencia humana. Incluye hasta simples reglas “si pasa X, haz Y”.

 MACHINE LEARNING (ML) — auge desde los 90

Subcampo de la IA: en vez de programar reglas a mano, la máquina descubre patrones estadísticos a partir de datos.

 DEEP LEARNING (DL) — explosión desde 2012

Subcampo del ML: usa redes neuronales artificiales con muchas capas para aprender patrones muy complejos (imágenes, voz, lenguaje).

 IA GENERATIVA (GenAI) — boom desde 2022

Subcampo del DL: no solo reconoce patrones, sino que CREA contenido nuevo: texto, imágenes, audio, video y código.

1 Inteligencia Artificial (IA): el término paraguas

💡 Definición precisa

La **Inteligencia Artificial** es la disciplina de la computación que busca construir sistemas capaces de realizar tareas que, si las hiciera un humano, diríamos que requieren inteligencia: percibir, razonar, decidir, planificar o comunicarse. Nació formalmente en la conferencia de Dartmouth en **1956** — sí, la IA tiene 70 años, no nació con los chatbots.

Punto clave que sorprende a muchos: la IA **no exige aprendizaje**. Un sistema puede ser “IA” usando solo reglas escritas a mano por programadores. A esto se le llama **IA simbólica o basada en reglas** (“sistemas expertos”): miles de instrucciones del tipo “SI la fiebre es mayor a 39° Y hay tos, ENTONCES sugiere gripe”.

✍️ IA clásica que usas sin saberlo

- ▶ El **GPS** que calcula tu ruta: usa algoritmos de búsqueda (como A*), no “aprende” de datos.
- ▶ El **rival de un videojuego de ajedrez clásico**: evalúa jugadas con reglas y árboles de decisión.
- ▶ Un **corrector ortográfico antiguo**: compara contra un diccionario con reglas fijas.

2 Machine Learning (ML): aprender de los datos

💡 Definición precisa

El **Machine Learning (aprendizaje automático)** es el subcampo de la IA donde el sistema **no recibe las reglas: las descubre solo**, analizando ejemplos. El programador ya no escribe “si el correo contiene la palabra GRATIS es spam”; en su lugar, le muestra a la máquina 100.000 correos etiquetados como “spam” o “no spam”, y ella encuentra estadísticamente qué características delatan al spam.

Este es el **giro copernicano** de toda la IA moderna, así que grábalo bien:

Programación tradicional	Machine Learning
Entra: reglas + datos	Entra: datos + respuestas correctas
Sale: respuestas	Sale: las reglas (el “modelo”)

Programación tradicional	Machine Learning
El humano escribe la lógica	La máquina deduce la lógica
Ejemplo: calculadora de impuestos	Ejemplo: filtro de spam de tu correo

ML en tu día a día

- ▶ Netflix o YouTube recomendándote contenido según lo que otros usuarios parecidos a ti vieron.
- ▶ Tu banco detectando una compra sospechosa con tu tarjeta (detección de fraude).
- ▶ La predicción del precio de una casa según metros cuadrados, barrio y antigüedad.

3 Deep Learning (DL): redes neuronales profundas

Definición precisa

El **Deep Learning (aprendizaje profundo)** es ML que utiliza **redes neuronales artificiales**: estructuras matemáticas inspiradas —muy libremente— en las neuronas del cerebro, organizadas en **capas**. “Profundo” (deep) significa literalmente “con muchas capas”: mientras el ML clásico usa modelos de 1 o 2 pasos, una red profunda puede tener decenas o cientos de capas apiladas.

¿Por qué importan las capas? Porque cada una aprende un nivel de abstracción distinto. En una red que reconoce rostros: la primera capa detecta bordes y líneas; la siguiente combina bordes en formas (ojos, narices); las capas superiores combinan formas en rostros completos. Nadie programó eso: **la jerarquía emerge sola del entrenamiento**. Esa capacidad de construir abstracciones es lo que permitió a las máquinas ver, escuchar y leer.

“Redes neuronales = cerebro digital”

Falso. La inspiración biológica es solo una metáfora histórica. Una “neurona” artificial es una operación matemática simple (multiplicar, sumar y aplicar una función). No hay biología, ni conciencia, ni pensamiento: hay **álgebra a escala industrial**. Tu cerebro tiene ~86.000 millones de neuronas biológicas con química, plasticidad y cuerpo; una red neuronal es una gigantesca hoja de cálculo optimizada.

**DL en acción**

- ▶ Desbloquear tu celular con tu cara (visión por computador).
- ▶ Los subtítulos automáticos de YouTube (reconocimiento de voz).
- ▶ El traductor automático que usas en vacaciones.

4 IA Generativa (GenAI): la que crea contenido

**Definición precisa**

La **IA Generativa** es el subcampo del Deep Learning cuyos modelos, en lugar de solo *clasificar o predecir* (“¿este correo es spam?”), **generan contenido nuevo**: texto, imágenes, música, video o código. Los más famosos son los **LLMs (Large Language Models, grandes modelos de lenguaje)** como Claude o GPT, que generan texto prediciendo, palabra por palabra, cuál es la continuación más probable de lo que llevan escrito.

Fíjate en el cambio de naturaleza: el ML tradicional es **discriminativo** (separa, clasifica, puntúa), mientras que la GenAI es **generativa** (produce algo que antes no existía). Un modelo discriminativo te dice “esta foto **ES** un gato”; uno generativo te *dibuja* un gato que jamás ha existido.

**“El chatbot entiende y sabe”**

Cuidado con el lenguaje. Un LLM no “sabe” cosas como tú: ha comprimido patrones estadísticos de billones de palabras y genera la continuación más plausible. Por eso puede **alucinar**: producir texto fluido, seguro... y falso. Suena convincente porque optimiza *plausibilidad*, no *verdad*. Regla de oro: la GenAI es un excelente asistente y un pésimo oráculo; verifica todo dato crítico.

**Tabla maestra: las cuatro capas frente a frente**

	IA (paraguas)	Machine Learning	Deep Learning	GenAI
¿Qué es?	Máquinas que hacen tareas “inteligentes”	La máquina aprende reglas desde datos	ML con redes neuronales de muchas capas	DL que crea contenido nuevo
¿Necesita datos?	No siempre (puede ser solo reglas)	Sí: miles de ejemplos	Sí: millones de ejemplos	Sí: billones de palabras/imágenes

	IA (paraguas)	Machine Learning	Deep Learning	GenAI
Hardware típico	Un PC común	Un PC o servidor normal	GPUs potentes	Clústeres de miles de GPUs
Ejemplo estrella	GPS, ajedrez clásico	Filtro de spam, predicción de precios	Reconocimiento facial y de voz	Claude, GPT, generadores de imagen
Era dorada	1956 en adelante	1990s–2000s	2012 en adelante	2022 en adelante

Cómo detectar qué “IA” te están vendiendo

Pregunta siempre: **¿el sistema aprende de datos o sigue reglas fijas?** Si sigue reglas: IA clásica. **¿Usa redes neuronales?** Si no: ML clásico. **¿Genera contenido nuevo o solo clasifica/predice?** Si genera: GenAI. Con tres preguntas desarmas el 95 % del humo del marketing.

Mini-actividad 0.1 – Clasifica sin mirar la tabla (3 min)

Clasifica cada sistema como **IA clásica**, **ML**, **DL** o **GenAI** y justifica en una línea:

- ▶ a) El semáforo “inteligente” que cambia según sensores de tráfico con reglas fijas.
- ▶ b) Una app que predice si lloverá mañana usando datos históricos del clima.
- ▶ c) La cámara de tu celular que detecta y enfoca rostros automáticamente.
- ▶ d) Una herramienta que redacta un correo completo a partir de tres palabras tuyas.

Respuestas al final del módulo (Glosario y soluciones). ¡No hagas trampa!

SECCIÓN 0.2

El ciclo de vida de un modelo: Entrenamiento vs. Inferencia

Aquí desmontamos el mito más extendido de todos: que la IA “aprende mientras hablas con ella”. Para entender por qué es falso, hay que conocer las **dos vidas** completamente separadas de todo modelo: primero se **entrena** (una vez, carísimo, durante meses) y luego se **usa** (millones de veces, barato, en segundos). A la fase de uso se le llama **inferencia**.



La analogía del estudiante y el examen

Entrenamiento = los años de estudio. El estudiante lee miles de libros, hace ejercicios, se equivoca, corrige y consolida conocimiento. Es lento, costoso y transforma su cerebro.

Inferencia = presentar el examen. El estudiante ya no aprende: *aplica* lo que sabe para responder rápido. Cada examen que presenta no cambia lo que estudió.

Cuando chateas con un modelo de IA, estás frente a un estudiante que **ya se graduó**: responde tus preguntas (inferencia), pero su “cerebro” quedó congelado el día que terminó de estudiar (entrenamiento).



Paso 1 — El dataset: la materia prima del aprendizaje



¿Qué es un dataset?

Un **dataset (conjunto de datos)** es una colección organizada de ejemplos con los que el modelo aprenderá. En el ML supervisado clásico, cada ejemplo trae dos partes: la **entrada** (lo que el modelo verá) y la **etiqueta** (la respuesta correcta que debería producir). El dataset es al modelo lo que los libros de texto al estudiante: define *todo lo que podrá saber*.

Así se ve un fragmento de dataset para entrenar un filtro de spam:

Entrada (texto del correo)	Etiqueta (respuesta correcta)
“¡GANASTE \$1.000.000! Haz clic AHORA”	SPAM 🚫
“Hola Ana, adjunto el informe de ventas del martes”	NO SPAM ✅
“Última oportunidad: pastillas milagrosas 90 % dcto.”	SPAM 🚫
“Recordatorio: reunión de equipo mañana a las 10 a. m.”	NO SPAM ✅

Basura entra, basura sale (GIGO)

El principio más importante de todo el ML: **un modelo nunca será mejor que sus datos**. Si el dataset tiene errores, sesgos o vacíos, el modelo los aprenderá religiosamente. Por eso en la industria se dice que el 80 % del trabajo real de IA es *limpiar y preparar datos*, no diseñar modelos. En inglés: Garbage In, Garbage Out.

Paso 2 — El bucle de entrenamiento: así “aprende” la máquina

Olvida la magia: el aprendizaje automático es un **bucle de tres pasos repetido millones de veces**. Míralo primero en versión humana y luego en código:

1. **Predecir:** el modelo (al principio, totalmente ignorante y aleatorio) mira una entrada y arriesga una respuesta.
2. **Medir el error:** se compara su respuesta con la etiqueta correcta usando una fórmula llamada **función de pérdida (loss)**, que produce un número: cuanto más grande, peor lo hizo.
3. **Ajustar:** un algoritmo (el **descenso de gradiente**) modifica ligeramente los números internos del modelo en la dirección que reduce el error. Como el juego “frío-caliente”: cada ajuste acerca al modelo un poquito a la respuesta correcta.

En código (versión ultra simplificada y comentada) el bucle se ve así:

```
entrenamiento.py – el corazón de todo el ML

1 # El bucle de entrenamiento: 3 pasos que se repiten millones de veces
2 for epoca in range(100):           # una 'época' = una pasada completa al
dataset
3     for entrada, etiqueta in dataset:
4         prediccion = modelo(entrada)    # 1) el modelo arriesga una
respuesta
5         error = perdida(prediccion, etiqueta) # 2) ¿qué tan mal quedó?
(loss)
6         ajustar_pesos(modelo, error)    # 3) corregir un poquito
(gradiente)
7
8 print("Modelo entrenado: los pesos quedan CONGELADOS")
```

Lectura línea por línea (para quien nunca ha visto código)

- **Línea 2:** “for ... in range(100)” significa “repite lo de adentro 100 veces”. Cada repetición completa sobre todos los datos se llama **época**.

- ▶ **Línea 3:** recorre el dataset ejemplo por ejemplo, tomando cada entrada con su etiqueta correcta.
- ▶ **Línea 4:** el modelo produce su predicción actual (al inicio será casi aleatoria).
- ▶ **Línea 5:** la función de pérdida convierte “qué tan equivocado estuvo” en un número medible.
- ▶ **Línea 6:** aquí ocurre el “aprendizaje”: se retocan los números internos para que la próxima vez el error sea menor.
- ▶ **Línea 8:** al terminar, los números internos se guardan y **no vuelven a cambiar**. Ese archivo congelado ES el modelo.

⚠ “Memorizar no es aprender”: el sobreajuste

Un peligro clásico: si entrenas demasiado sobre los mismos datos, el modelo puede **memorizarlos** en lugar de captar el patrón general. Es el estudiante que se aprende el examen del año pasado de memoria: saca 10 en ese examen y 2 en cualquier otro. A esto se le llama **sobreajuste (overfitting)**. Por eso siempre se reserva una parte del dataset (**datos de validación**) que el modelo nunca ve durante el entrenamiento: sirve para comprobar si de verdad generalizó o solo memorizó.

⚡ Paso 3 — La inferencia: el modelo en acción

💡 ¿Qué es la inferencia?

La **inferencia** es usar el modelo ya entrenado para obtener respuestas sobre datos nuevos. No hay bucle, no hay corrección de errores, no hay aprendizaje: solo un **cálculo de ida** — la entrada atraviesa la red, capa por capa, y sale una respuesta. Cada mensaje que envías a un chatbot dispara una inferencia.

Aspecto	🏆 Entrenamiento	⚡ Inferencia
¿Qué pasa?	El modelo se construye: sus números internos cambian millones de veces	El modelo se usa: sus números están congelados
¿Cuántas veces?	Una vez (o pocas, por versión)	Millones de veces al día
Duración	Semanas o meses	Milisegundos a segundos
Costo típico (2026)	Decenas o cientos de millones de USD para un modelo frontera	Fracciones de centavo por consulta
Hardware	Clústeres de miles de GPUs	Desde una GPU hasta el chip de tu celular

Aspecto	🏆 Entrenamiento	⚡ Inferencia
¿Quién lo hace?	Los laboratorios de IA (Anthropic, Google, Meta...)	Tú, cada vez que usas la app
Analogía	Años de estudio	Presentar el examen

⚠️ “La IA aprende de mi conversación en tiempo real”

Falso en el sentido técnico. Durante el chat, el modelo **no modifica ni un solo peso**: solo mantiene tu conversación en una memoria temporal llamada **ventana de contexto** (como notas en un borrador). Al cerrar la sesión, esas notas se descartan. Si el proveedor quiere que el modelo “mejore”, debe lanzar un *nuevo entrenamiento* y publicar una nueva versión. Por eso los modelos tienen **fecha de corte de conocimiento**: el mundo posterior a su entrenamiento simplemente no existe para ellos (salvo que consulten herramientas externas, como buscadores).

🔧 Vocabulario que escucharás en la industria

- ▶ **Pre-entrenamiento**: la fase gigante inicial con datos masivos de internet.
- ▶ **Ajuste fino (fine-tuning)**: re-entrenar levemente un modelo ya listo para especializarlo (lo veremos en módulos futuros).
- ▶ **Despliegue (deployment)**: poner el modelo en servidores para que el público haga inferencia.
- ▶ **Checkpoint**: una “foto” guardada de los pesos del modelo en cierto punto del entrenamiento.

✎ Mini-actividad 0.2 – ¿Entrenamiento o inferencia? (2 min)

Marca E (entrenamiento) o I (inferencia):

- ▶ a) Le pides a un chatbot que resuma un contrato.
- ▶ b) Un laboratorio procesa 15 billones de palabras durante 3 meses en 20.000 GPUs.
- ▶ c) Tu celular traduce un letrero con la cámara, sin internet.
- ▶ d) Un banco reajusta su modelo antifraude con las transacciones del último año.

Pista: pregunta siempre “¿están cambiando los pesos del modelo o solo usándolos?”

SECCIÓN 0.3

Anatomía física de la IA: pesos, parámetros y hardware

Ya sabes que un modelo “aprende” ajustando números internos. En esta sección abrimos el capó: ¿qué son exactamente esos números, por qué se cuentan por miles de millones y por qué mover todo eso exige chips especiales y montañas de memoria? Spoiler: al final de la sección podrás calcular tú mismo cuánta memoria necesita cualquier modelo.



Pesos y parámetros: las perillas del modelo



La analogía del ecualizador gigante

Imagina la mesa de sonido de un estudio, llena de perillas: cada una sube o baja algo (graves, agudos, eco...). Ajustando la combinación correcta de perillas, cualquier voz suena perfecta. Ahora imagina una mesa con **70.000 millones de perillas**. Eso es un modelo de IA: cada perilla es un **peso**, y “entrenar” es girarlas todas, poquito a poquito, millones de veces, hasta que la salida “suene bien” para casi cualquier entrada.



Definiciones exactas

Peso (weight): un número decimal (por ejemplo, 0.7213 o -1.0448) que determina cuánta importancia da una neurona artificial a una de sus entradas. Es la unidad mínima de “conocimiento” del modelo.

Parámetros: el conjunto total de números ajustables del modelo: todos los pesos más unos números auxiliares llamados **sesgos (biases)**. En la práctica, “parámetros” y “pesos” se usan casi como sinónimos.

Cuando lees “Llama 3 de **70B**”, la B significa *billions* en inglés: 70.000 millones de parámetros. Ojo con la traducción: el billion inglés son mil millones, no el billón hispano.

Y aquí viene la idea que lo cambia todo: el modelo entrenado **no es un programa misterioso, es un archivo**. Un archivo gigante lleno de esos números, nada más. Cuando alguien “descarga un modelo”, descarga esa lista de miles de millones de decimales organizados en tablas (matrices). Todo el “conocimiento” del modelo — gramática, datos, estilos, razonamiento aparente — está codificado en cómo quedaron distribuidos esos números tras el entrenamiento. Es asombroso y a la vez profundamente anticlimático.

! “En algún lugar del modelo está guardada la Wikipedia”

No. El modelo no contiene documentos, ni bases de datos, ni frases guardadas para copiar y pegar. La información quedó **comprimida y diluida estadísticamente** entre miles de millones de pesos, de forma parecida a como tus recuerdos no están en una neurona concreta sino repartidos en conexiones. Por eso no se puede “borrar un dato” de un modelo con la tecla suprimir: habría que re-entrenarlo.



¿Cuánta memoria necesita un modelo? La cuenta que todos deberían saber

Cada parámetro es un número, y guardar un número ocupa memoria. La precisión estándar en 2026 para inferencia es **FP16/BF16** (números de 16 bits = **2 bytes** cada uno). La fórmula servilleta es:

$$\text{Memoria} \approx \text{nº de parámetros} \times \text{bytes por parámetro}$$

```

calcula_vram.py — hazlo con cualquier modelo

1 # ¿Cuánta VRAM necesita un modelo de 7B en distintas precisiones?
2 parametros = 7_000_000_000      # 7B = siete mil millones
3
4 for nombre, bytes_param in [("FP32", 4), ("FP16", 2), ("INT4", 0.5)]:
5     gb = parametros * bytes_param / 1024**3
6     print(f"{nombre}: ~{gb:.1f} GB de VRAM")
7
8 # Salida:  FP32: ~26.1 GB   FP16: ~13.0 GB   INT4: ~3.3 GB
  
```

Es decir: para que un modelo de 7B responda en precisión estándar, hay que tener **~13–14 GB de memoria de video (VRAM) libres, todos al mismo tiempo**. Y esto es solo para *guardar* el modelo: la conversación en curso consume memoria adicional.

Tamaño del modelo	VRAM en FP16	VRAM en INT4 (comprimido)	¿Dónde corre en 2026?
1B (pequeño)	~2 GB	~0.5 GB	Celulares y laptops comunes
7–8B (mediano)	~14 GB	~4 GB	Laptop gamer o PC con buena GPU
70B (grande)	~140 GB	~35 GB	Estación de trabajo o servidor
400B+ (frontera)	800 GB+	200 GB+	Solo clústeres en la nube

💡 Cuantización: poner el modelo a dieta

La **cuantización** reduce la precisión de cada peso (de 16 bits a 8 o 4 bits) para que el modelo ocupe menos memoria. Es como comprimir una foto a JPG: pierdes un poco de calidad a cambio de un archivo mucho más liviano. Gracias a la cuantización a 4 bits (INT4), modelos que antes exigían un servidor hoy corren en una laptop. Es la tecnología que hizo posible la IA local.

🔧 ¿Por qué VRAM y no el disco duro?

Porque para generar **cada palabra** de una respuesta, el chip debe consultar prácticamente **todos los pesos del modelo**. Si estuvieran en el disco (lento), cada palabra tardaría minutos. La analogía: la VRAM es tu *escritorio* — todo a la mano, acceso instantáneo — y el disco es la *biblioteca del sótano*. Un modelo solo es usable si cabe completo sobre el escritorio. Por eso la pregunta clave al comprar hardware para IA no es “¿cuántos GHz?” sino “¿cuánta VRAM?”

🖥️ El zoológico de chips en 2026: CPU, GPU, TPU y NPU

El Deep Learning es, en el fondo, multiplicar tablas de números gigantescas (matrices). Esa tarea no requiere un genio que resuelva problemas complejos uno por uno: requiere **millones de sumas y multiplicaciones simples, todas a la vez**. De ahí nace la división del trabajo entre chips:

✍️ La analogía del profesor y los 10.000 estudiantes

Una **CPU** es como 8 o 16 profesores brillantes: resuelven cualquier problema, pero de a uno. Una **GPU** es como 10.000 estudiantes de primaria que solo saben sumar y multiplicar... pero lo hacen **todos al mismo tiempo**. Para pintar millones de píxeles (su trabajo original en videojuegos) o multiplicar matrices gigantes, el ejército de estudiantes aplasta a los profesores. Ese descubrimiento —que los chips de videojuegos eran perfectos para redes neuronales— encendió la revolución del Deep Learning en 2012.

Chip	Nombre completo	¿Dónde vive?	¿En qué brilla?	Ejemplos 2026
CPU	Unidad Central de Procesamiento	Todo computador	Tareas generales y secuenciales; orquestar el sistema	Intel Core, AMD Ryzen, Apple M
GPU	Unidad de Procesamiento Gráfico	PCs gamer, estaciones, centros de datos	Paralelismo masivo: entrenar e inferir modelos grandes	NVIDIA H200/B200, RTX 50, AMD Instinct

Chip	Nombre completo	¿Dónde vive?	¿En qué brilla?	Ejemplos 2026
TPU	Unidad de Procesamiento Tensorial	Nube de Google (no se venden al público)	Multipliación de tensores a escala industrial, gran eficiencia energética	Google TPU v6/v7
NPU	Unidad de Procesamiento Neuronal	Dentro de celulares y laptops modernas	Inferencia local de modelos pequeños con bajísimo consumo de batería	Apple Neural Engine, Snapdragon, Intel AI Boost

Nota el patrón de 2026: **entrenar** sigue siendo territorio de GPUs y TPUs en centros de datos, pero la **inferencia** se está mudando a los bolsillos: casi todo celular y laptop nuevos traen una NPU dedicada para ejecutar IA local sin internet y sin agotar la batería. Este movimiento —del centro de datos al dispositivo— se llama **IA en el borde (edge AI)** y conecta directamente con la próxima sección.

Si vas a comprar equipo para experimentar con IA

- ▶ Prioriza **VRAM sobre velocidad**: una GPU con 16 GB “lenta” corre modelos que una de 8 GB “rápida” ni siquiera puede cargar.
- ▶ Las **Mac con chips M** usan memoria unificada (RAM compartida con la GPU): una Mac con 32 GB puede cargar modelos sorprendentemente grandes.
- ▶ Para empezar **no compres nada**: los modelos en la nube y los servicios gratuitos bastan para todo este curso.

Mini-actividad 0.3 – La cuenta de la servilleta (3 min)

Con la fórmula **memoria = parámetros × bytes**, calcula:

- ▶ a) ¿Cuánta VRAM necesita un modelo de 3B en FP16 (2 bytes)?
- ▶ b) ¿Y un 13B cuantizado a INT4 (0.5 bytes)?
- ▶ c) Tu laptop tiene 8 GB de VRAM: ¿cuál es el modelo más grande en FP16 que podrías cargar (aprox.)?

Soluciones al final del módulo. Redondea sin miedo: en IA las cuentas de servilleta son cultura oficial.

SECCIÓN 0.4

Modelos Fundacionales vs. Modelos Pequeños (SLMs)

Última pieza del rompecabezas conceptual: no todos los modelos son gigantes en la nube. En 2026 conviven dos filosofías — el **todoterreno colosal** y el **especialista de bolsillo** — y saber elegir entre ellas es una de las decisiones de ingeniería más importantes al construir cualquier producto con IA.



Modelos fundacionales: los gigantes de propósito general



Definición precisa

Un **modelo fundacional (foundation model)** es un modelo de enorme escala, entrenado con una porción gigantesca de internet (texto, código, imágenes...), diseñado para servir de **base de propósito general**: conversar, traducir, programar, analizar, resumir... todo con el mismo modelo. Ejemplos en 2026: **Claude (Anthropic)**, **GPT-5 (OpenAI)**, **Gemini (Google)**, **Llama (Meta)**. Se llaman “fundacionales” porque, como los cimientos de un edificio, sobre ellos se construyen miles de aplicaciones distintas.

Sus características definitorias: cientos de miles de millones (o billones) de parámetros; entrenamiento que cuesta cifras de nueve dígitos; y una consecuencia física inevitable que ya puedes deducir de la sección 0.3: **no caben en tu computador**. Viven en centros de datos y tú los usas por internet — desde una app de chat o mediante una **API** (una “puerta de servicio” por la que los programas envían preguntas al modelo y reciben respuestas; las verás en acción en módulos futuros).



SLMs: pequeños, rápidos y tuyos



Definición precisa

Un **SLM (Small Language Model, modelo de lenguaje pequeño)** es un modelo de entre ~0.5B y ~14B parámetros, diseñado para correr **localmente** — en tu laptop, tu celular o un servidor modesto — y a menudo **optimizado para tareas específicas**: resumir correos, clasificar tickets de soporte, autocompletar código de un lenguaje concreto. Ejemplos de familias populares en 2026: **Phi (Microsoft)**, **Gemma (Google)**, **Llama pequeños (Meta)**, **Qwen (Alibaba)**, **Mistral**.

Hospital general vs. médico de cabecera

Un modelo fundacional es un **hospital universitario**: tiene todos los especialistas del mundo, resuelve los casos más difíciles... pero queda lejos, tiene filas y cada visita cuesta. Un SLM es tu **médico de cabecera en la esquina**: atiende al instante, te conoce, es baratísimo y resuelve el 80 % de los casos cotidianos. Nadie va al hospital universitario por una gripe — y nadie debería pagar un modelo frontera para clasificar correos en “urgente / no urgente”.

La comparación definitiva

Criterio	 Fundacional (nube)	 SLM (local)
Tamaño típico	100B – 2T+ parámetros	0.5B – 14B parámetros
¿Dónde corre?	Centros de datos del proveedor	Tu laptop, celular o servidor propio
Calidad general	La máxima disponible; razona tareas complejas	Muy buena en su nicho; limitada en tareas abiertas complejas
Costo de uso	Pago por consulta o suscripción	Casi cero tras la inversión inicial en hardware
Privacidad	Tus datos viajan a servidores de terceros	Los datos nunca salen de tu dispositivo
¿Necesita internet?	Siempre	No: funciona en un avión o en zona rural
Latencia	Depende de la red y de la carga del servicio	Instantánea y predecible
Personalización	Limitada a lo que permita el proveedor	Total: puedes ajustarlo (fine-tuning) a tu dominio
Mantenimiento	Cero: el proveedor actualiza todo	Tuyo: instalar, actualizar, monitorear

¿Cuál elegir? La regla de decisión

Guíate por estos cuatro escenarios típicos — cubren la mayoría de los casos reales:

Situación	Elección recomendada	¿Por qué?
Tareas variadas y complejas (investigar, redactar, programar)	Fundacional ☁	Necesitas la máxima capacidad y flexibilidad de propósito general
Datos sensibles (historias clínicas, contratos, secretos industriales)	SLM local 🗝	La información nunca abandona tu infraestructura

Situación	Elección recomendada	¿Por qué?
Una tarea repetitiva y acotada a gran volumen (clasificar, extraer, resumir)	SLM 	Calidad suficiente a una fracción del costo por consulta
App móvil que debe funcionar sin conexión	SLM en la NPU 	Inferencia en el dispositivo: sin internet, sin latencia, sin costo por uso

La arquitectura híbrida: lo mejor de ambos mundos

La tendencia dominante en 2026 no es “o uno o el otro”, sino **enrutamiento (routing)**: un SLM local atiende primero todas las consultas; si detecta que la tarea le queda grande, la escala al modelo fundacional en la nube. Como un consultorio que remite al hospital solo los casos graves. Resultado: 80–90 % de consultas resueltas gratis y al instante, con la potencia del gigante disponible cuando de verdad hace falta.

“Más grande siempre es mejor”

El mito favorito de 2023, muerto en 2026. Para una tarea específica, un SLM bien ajustado puede **igualar o superar** a un gigante genérico — gastando la milésima parte de energía y dinero. La pregunta profesional nunca es “¿cuál es el mejor modelo del mundo?” sino “**¿cuál es el modelo más pequeño que resuelve MI tarea con la calidad que necesito?**” Esa sola pregunta distingue al aficionado del ingeniero.

Mini-actividad 0.4 — Tú eres el arquitecto (3 min)

Para cada caso, decide: ¿fundacional, SLM local o híbrido? Justifica en una línea:

- ▶ a) Una clínica quiere resumir historias médicas confidenciales.
- ▶ b) Un estudiante necesita ayuda con ensayos, código y traducciones.
- ▶ c) Una app de senderismo debe responder preguntas sobre plantas sin señal en la montaña.
- ▶ d) Una empresa quiere un asistente interno: 90 % preguntas simples de RR. HH., 10 % análisis complejos.

EVALUACIÓN PRÁCTICA



Tres retos para consolidar el módulo

La teoría solo se vuelve conocimiento cuando la usas. Estos tres retos están diseñados para trabajarse **sin ninguna herramienta especial** — solo papel, tu computador o celular, y lo aprendido. Guarda tus entregables: los reutilizaremos en módulos futuros.

RETO 1 — El clasificador humano · 30-45 min · Dificultad:

Objetivo: demostrar que dominas la taxonomía de la sección 0.1 aplicándola al mundo real.

Pasos:

1. Haz una lista de 10 apps, servicios o dispositivos con “inteligencia” que uses en tu vida diaria (redes sociales, banco, GPS, cámara, asistente de voz, streaming...).
2. Clasifica cada uno en: IA clásica (reglas), ML, DL o GenAI.
3. Justifica cada clasificación en una sola línea usando las tres preguntas del “detector de humo” de la sección 0.1.
4. Marca con los casos dudosos y escribe por qué dudas (las dudas bien argumentadas valen más que las certezas copiadas!).

Entregable: una tabla de 10 filas × 3 columnas (sistema, categoría, justificación).

Criterio de éxito: al menos 8 clasificaciones correctamente argumentadas y mínimo un caso dudoso analizado con honestidad.

RETO 2 — Detective de hardware · 45-60 min · Dificultad:

Objetivo: aplicar la aritmética de memoria de la sección 0.3 a TU propio equipo.

Pasos:

1. Investiga las especificaciones de tu computador y de tu celular: RAM total, ¿tiene GPU dedicada y con cuánta VRAM?, ¿tiene NPU? (búscalo en “Acerca de este equipo” o en la ficha técnica del fabricante).
2. Con la fórmula memoria = parámetros × bytes, calcula el modelo más grande que cada dispositivo podría cargar en FP16 (2 bytes) y en INT4 (0.5 bytes).
3. Compara tu resultado con la tabla de tamaños de la sección 0.3 y clasifica tus dispositivos: ¿en qué liga juegan?
4. Escribe una conclusión de 5 líneas: ¿podrías correr IA local hoy? ¿Qué te limita: la memoria, el chip o nada?

Entregable: mini-informe de una página con la ficha de cada dispositivo, los cálculos y la conclusión.

Criterio de éxito: cálculos correctos (se permite redondear) y conclusión coherente con los números obtenidos.

🏆 **RETO 3 — Explícaselo a tu abuela** · ⌚ **30 min** · **Dificultad:** ★★★★★ (¡la más difícil!)

Objetivo: la prueba de fuego del entendimiento — Feynman decía que si no puedes explicarlo simple, no lo entiendes.

Pasos:

1. Elige un “alumno”: una persona real que no sepa nada de IA (familiar, amigo).
2. Prepara una explicación hablada de máximo 90 segundos sobre la diferencia entre entrenamiento e inferencia.
3. **Regla estricta:** está prohibido usar la analogía del estudiante y el examen de este libro. Debes inventar una analogía propia (cocinar, deportes, música, jardinería... lo que domines).
4. Dale en vivo (o grábate en audio/video) y pídele a tu alumno que te la explique de vuelta con sus palabras.

Entregable: el texto o grabación de tu explicación + dos líneas sobre qué entendió (o no) tu alumno.

Criterio de éxito: tu alumno logra responder correctamente: “cuando uso un chatbot, ¿el modelo está aprendiendo de mí?” Si responde bien, tu analogía funcionó.

MATERIAL DE REFERENCIA

 Glosario del módulo

Dieciséis términos que ya conquistaste. Vuelve a esta página cada vez que un término se te escape — repasar el glosario 48 horas después de leer multiplica la retención.

Término	Definición en una frase
IA (Inteligencia Artificial)	Disciplina que busca que las máquinas realicen tareas que asociamos con inteligencia humana; incluye desde reglas fijas hasta redes neuronales.
Machine Learning (ML)	Subcampo de la IA donde la máquina descubre patrones a partir de datos en lugar de recibir reglas programadas.
Deep Learning (DL)	ML basado en redes neuronales de muchas capas, capaz de aprender abstracciones complejas (visión, voz, lenguaje).
IA Generativa (GenAI)	DL que crea contenido nuevo (texto, imagen, audio, código) en lugar de solo clasificar o predecir.
LLM	Large Language Model: modelo generativo gigante especializado en lenguaje, que escribe prediciendo la siguiente palabra.
Dataset	Colección organizada de ejemplos (entrada + etiqueta) con la que se entrena un modelo.
Entrenamiento (training)	Fase en la que los pesos del modelo se ajustan millones de veces para minimizar el error sobre el dataset.
Inferencia (inference)	Fase de uso: el modelo, con pesos congelados, produce respuestas sobre datos nuevos.
Función de pérdida (loss)	Fórmula que mide en un número qué tan equivocada estuvo una predicción.
Sobreajuste (overfitting)	Cuando el modelo memoriza el dataset en vez de aprender el patrón general, y falla con datos nuevos.
Peso / Parámetro	Cada número ajustable del modelo; su conjunto codifica todo el 'conocimiento' aprendido.
VRAM	Memoria de la tarjeta gráfica; el modelo completo debe caber en ella para funcionar con rapidez.
Cuantización	Compresión de los pesos a menor precisión (p. ej., 4 bits) para que el modelo ocupe menos memoria.
GPU / TPU / NPU	Chips especializados en el cálculo paralelo masivo de la IA: la GPU es de propósito gráfico/IA, la TPU es de Google para la nube y la NPU vive en celulares y laptops.
Modelo fundacional	Modelo gigante de propósito general entrenado con datos masivos, sobre el que se construyen aplicaciones (Claude, GPT-5, Gemini).
SLM	Small Language Model: modelo pequeño (≈0.5–14B) que corre localmente, ideal para tareas específicas, privacidad y uso sin internet.

✓ Soluciones de las mini-actividades

Mini-actividad 0.1 (taxonomía)

- ▶ **a) IA clásica:** reglas fijas con sensores; no aprende de datos.
- ▶ **b) ML:** aprende patrones de datos históricos para predecir; no requiere redes profundas.
- ▶ **c) DL:** la detección de rostros en tiempo real usa redes neuronales convolucionales (visión por computador).
- ▶ **d) GenAI:** genera contenido nuevo (el texto del correo) a partir de una instrucción.

Mini-actividad 0.2 (entrenamiento vs. inferencia)

- ▶ **a) I** — usas el modelo; sus pesos no cambian. **b) E** — se están ajustando los pesos a escala masiva.
- ▶ **c) I** — inferencia local en la NPU del celular. **d) E** — re-entrenamiento (ajuste) del modelo con datos nuevos.

Mini-actividad 0.3 (cuentas de servilleta)

- ▶ **a)** $3B \times 2 \text{ bytes} \approx 6 \text{ GB}$ de VRAM.
- ▶ **b)** $13B \times 0.5 \text{ bytes} \approx 6.5 \text{ GB}$ de VRAM.
- ▶ **c)** $8 \text{ GB} \div 2 \text{ bytes} \approx$ modelos de hasta $\sim 3\text{--}4B$ en FP16 (dejando espacio para la conversación).

Mini-actividad 0.4 (arquitecto)

- ▶ **a) SLM local** (privacidad de datos médicos). **b) Fundacional** (tareas variadas y complejas).
- ▶ **c) SLM en la NPU** (sin conexión). **d) Híbrido con enrutamiento** (SLM para lo simple, nube para lo complejo).

🚀 Cierre: lo que acabas de lograr

Piénsalo un momento: hace unas páginas “IA” era una palabra de marketing. Ahora sabes que es una jerarquía precisa de disciplinas (0.1), que los modelos tienen dos vidas separadas —aprender y actuar— (0.2), que su “conocimiento” son miles de millones de números que exigen memoria y chips especiales (0.3), y que elegir entre un gigante en la nube y un especialista local es una decisión de ingeniería con criterios claros (0.4). Ese es exactamente el vocabulario y el mapa mental con el que trabajan los profesionales del área.



Autoevaluación final — marca solo lo que puedas hacer SIN mirar el libro

- ▶ ☐ Dibujar de memoria las cuatro capas anidadas: IA $\supset$ ML $\supset$ DL $\supset$ GenAI, con un ejemplo de cada una.
- ▶ ☐ Explicar por qué un chatbot NO aprende de mis conversaciones.
- ▶ ☐ Calcular la VRAM aproximada de un modelo dado su número de parámetros.
- ▶ ☐ Nombrar la diferencia entre GPU, TPU y NPU y dónde vive cada una.
- ▶ ☐ Recomendar fundacional, SLM o híbrido ante un caso concreto, con argumentos.

¿Las cinco marcadas y los tres retos entregados? Módulo 0 conquistado. Nos vemos en el siguiente módulo. 🎓